



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

TP2 - Reconocimiento de Dígitos

May 18, 2022

Métodos Numéricos

Grupo 8

Integrante	LU	Correo electrónico
Cappella Lewi, F. Galileo	653/20	galileocapp@gmail.com
Anachure, Juan Pablo	99/16	janachure@gmail.com
La Tessa, Octavio	477/16	octalate@hotmail.com

En este trabajo utilizamos técnicas matriciales para reconocer dígitos en imágenes

Palabras clave:

Reconocimiento de Dígitos	C++
Primary Component Analysis (PCA)	K-Nearest Neighbors



Facultad de Ciencias Exactas y Naturales

Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2610 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (+54 +11) 4576-3300

<https://exactas.uba.ar>

Secciones

1	Introducción	2
2	Desarrollo	2
2.1	Modelo	2
2.2	Auto α	2
2.3	Implementación	2
2.3.1	Optimización KNN	2
2.4	Datos	2
3	Experimentación	2
3.1	Maximización	2
3.1.1	Parámetros	2
3.1.2	Tamaño de entrenamiento	2
3.2	Limitación PCA	2
4	Conclusión	2
I	Justificación Optimización KNN	3
II	Demostración SVD	3

1 Introducción

2 Desarrollo

Para el análisis armamos un módulo de `python`.

2.1 Modelo

2.2 Auto α

2.3 Implementación

El módulo fue implementado en `c++` usando la librería Eigen y con pybind11 lo compilamos para usarlo desde `python`.

Aprovechamos la librería OpenMP para paralelizar las operaciones de Eigen.

2.3.1 Optimización KNN

Originalmente calculábamos los k vecinos más cercanos calculando la distancia entre , lo que es $\Theta(TODO)$.

Esto fue mejorado para en cambio calcular una matriz $D \in \mathbb{R}^{n \times m}$ que en la posición $D_{i,j}$ tiene la distancia al cuadrado entre el vector de entrenamiento i y el vector de prueba j , lo que reduce las operaciones necesarias para encontrar las k distancias más chicas y es más simple de paralelizar. En total (sin paralelizar) toma $\Theta(TODO)$ esto implica una mejora sustancial en el tiempo calcular lo buscado.

2.4 Datos

Los datos de dígitos los obtuvimos de la competencia "Digit Recognizer" de Kaggle

3 Experimentación

3.1 Maximización

3.1.1 Parámetros

3.1.2 Tamaño de entrenamiento

3.2 Limitación PCA

4 Conclusión

I Justificación Optimización KNN

Siendo $A \in \mathbb{R}^{n \times d}$, $B \in \mathbb{R}^{m \times d}$, quiero armar una matriz $D \in \mathbb{R}^{n \times m}$: $D_{i,j} = ||\text{row}_i(A) - \text{row}_j(B)||_2^2$.

Para ello, tomo $S_A \in \mathbb{R}^{n \times m}$: $S_{Ai,j} = ||\text{row}_i(A)||_2^2$, $S_B \in \mathbb{R}^{n \times m}$: $S_{Bi,j} = ||\text{row}_i(B)||_2^2$.

Y demuestro que $D = S_A - 2AB^t + S_B$:

$$D = S_A - 2AB^t + S_B \iff$$

$$\begin{aligned} D_{i,j} &= (S_A - 2AB^t + S_B)_{i,j} \leftarrow X = Y \iff X_{i,j} = Y_{i,j} \\ &= S_{Ai,j} - (2AB^t)_{i,j} + S_{Bi,j} \leftarrow (X - Y)_{i,j} = X_{i,j} - Y_{i,j} \\ &= S_{Ai,j} - 2(AB^t)_{i,j} + S_{Bi,j} \leftarrow \alpha X_{i,j} = \alpha X_{i,j} \\ &= S_{Ai,j} - 2\text{row}_i(A)\text{col}_j(B^t) + S_{Bi,j} \leftarrow (XY)_{i,j} = \text{row}_i(X)\text{col}_j(Y) \\ &= S_{Ai,j} - 2\text{row}_i(A)\text{row}_j^t(B) + S_{Bi,j} \leftarrow \text{row}_i^t(X) = \text{col}_i(X^t) \\ &= ||\text{row}_i(A)||_2^2 - 2\text{row}_i(A)\text{row}_j^t(B) + ||\text{row}_j(B)||_2^2 \leftarrow \text{Definición previa} \\ &= \text{row}_i^t(A)\text{row}_i(A) - 2\text{row}_i(A)\text{row}_j^t(B) + \text{row}_j^t(B)\text{row}_j(B) \leftarrow ||v||_2^2 = v^t v \\ &= (\text{row}_i(A) - \text{row}_j(B))^t (\text{row}_i(A) - \text{row}_j(B)) \leftarrow (v - w)^t (v - w) = v^t v - 2v^t w + w^t w \\ &= ||\text{row}_i(A) - \text{row}_j(B)||_2^2 \square \leftarrow ||v||_2^2 = v^t v \end{aligned}$$

II Demostración SVD

Figuras

Bibliografía